Classification de masses mammaires par vote pondéré : application de Golub à WDBC

Oskar Glendek **Seed personnelle : 23**

Code Python et notebook : *https://github.com/OskarG04/MLBIO*

1 Question et données

1.1 Objectif de l'étude

La question est de savoir si le vote pondéré proposé par Golub et ses collaborateurs permet de classer des échantillons mammaires malins avec une précision et une robustesse suffisantes. La méthode provient d'un travail sur l'expression génique de leucémies [1]. Ici, elle est appliquée à des mesures de morphologie nucléaire. L'étude porte donc sur son applicabilité à un autre type de données, et non sur la reproduction des résultats originaux.

1.2 Population et entrée du modèle

Le fichier fourni contient **569 patients**, dont **357 cas bénins** (62,7 %) et **212 cas malins** (37,3 %). Il comprend 30 variables numériques, un identifiant local et un diagnostic. Aucune valeur manquante n'est présente. L'identifiant est exclu des prédicteurs ; le diagnostic est encodé par 1 pour malin et 0 pour bénin. L'intégrité du fichier a été vérifiée contre le SHA256 du manifeste fourni.

Les données WDBC proviennent de travaux de Wolberg, Street et Mangasarian [2, 3, 4]. Une masse mammaire est prélevée par ponction à l'aiguille fine, les cellules sont placées sur une lame numérisée, puis leurs noyaux sont identifiés. Dix propriétés sont extraites et résumées sous trois formes : moyenne, erreur standard et moyenne des trois plus grandes valeurs (*worst*). Le modèle reçoit ces résumés numériques, sans accéder aux images.

Propriété	Interprétation
Rayon	Distance du centre nucléaire aux points du contour
Texture	Dispersion des niveaux de gris
Périmètre et aire	Longueur du contour et surface nucléaire
Lissage	Variations locales des longueurs des rayons
Compacité	Mesure fondée sur le rapport périmètre^2/aire
Concavité et points concaves	Irrégularités concaves du contour
Symétrie	Symétrie de la forme nucléaire
Dimension fractale	Complexité du contour

Table 1: Les dix propriétés à l'origine des trente variables.

Périmètre clinique. Les patients présentaient déjà une masse ayant été prélevée. Les 569 observations constituent une série de développement ; les 54 nouveaux patients de test mentionnés dans l'étude de 1994 ne sont pas inclus. Il ne s'agit pas d'une population de dépistage.

2 Exploration descriptive

2.1 Lien entre morphologie et diagnostic

Les moyennes de plusieurs mesures de taille et d'irrégularité du contour sont plus élevées chez les cas malins. Le tableau 2 illustre ces différences. Elles décrivent une association dans cet échantillon et ne suffisent pas à établir une règle diagnostique universelle.

Variable	Bénin	Malin
`mean_radius`	12,1465	17,4628
`mean_texture`	17,9148	21,6049
`mean_area`	462,7902	978,3764
`worst_concave_points`	0,0744	0,1822

Table 2: Moyennes par diagnostic, sur l'ensemble des données.

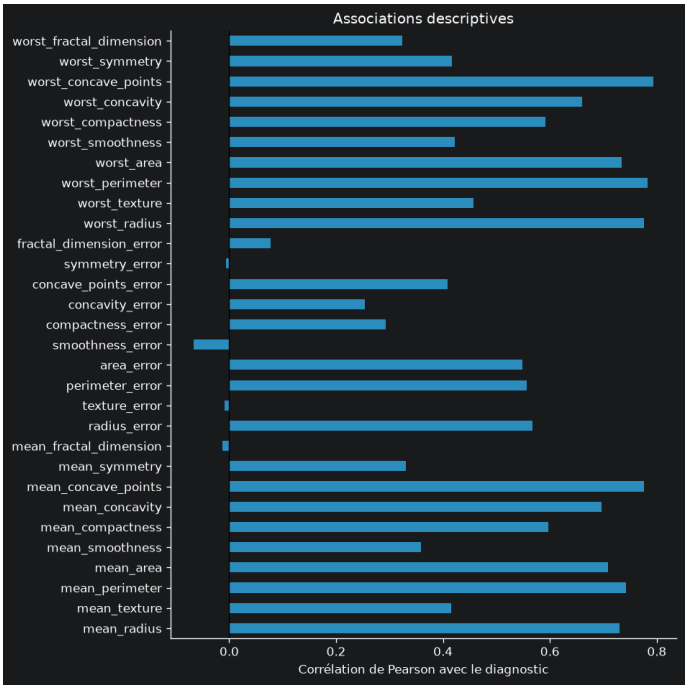


Figure 1: Corrélation de Pearson entre chaque variable et le diagnostic binaire (malin = 1). Analyse descriptive uniquement.

Les associations les plus fortes concernent les points concaves extrêmes ($r = 0,794$), le périmètre extrême ($r = 0,783$) et les points concaves moyens ($r = 0,777$). La dimension fractale moyenne présente, à l'inverse, une corrélation proche de zéro. Une faible association linéaire isolée ne prouve toutefois pas l'absence de toute information prédictive.

2.2 Séparation entre description et sélection

Les corrélations et moyennes globales ne servent pas à choisir les variables du classificateur. La sélection est recalculée dans chaque pli d'entraînement. Les variables décrivent aussi des propriétés liées : rayon, périmètre et aire caractérisent notamment la taille. Plusieurs variables retenues peuvent donc porter une information redondante, sans constituer dix mécanismes biologiques indépendants.

3 Méthode de vote pondéré

3.1 Poids et sélection

Pour chaque variable j, les moyennes $\mu_{j,0}$ et $\mu_{j,1}$ et les écarts-types $\sigma_{j,0}$ et $\sigma_{j,1}$ sont calculés respectivement sur les patients bénins et malins de l'entraînement. Le poids est défini par :

$$w_j = \frac{\mu_{j,1} - \mu_{j,0}}{\sigma_{j,1} + \sigma_{j,0}}. \tag{1}$$

Un poids positif indique une moyenne plus élevée chez les cas malins. Une grande valeur absolue indique une différence importante relativement à la dispersion dans les deux classes. Les dix variables ayant les plus grands $|w_j|$ forment l'ensemble S. Ce nombre est fixé par le sujet, sans optimisation sur les données.

3.2 Score et décision

Le milieu des deux moyennes est $b_j = (\mu_{j,1} + \mu_{j,0})/2$. Pour un patient x, le score est :

$$V(x) = \sum_{j \in S} w_j (x_j - b_j). \tag{2}$$

Le diagnostic prédit est malin lorsque $V(x) \geq 0$, et bénin sinon. Le score est une somme de contributions numériques ; ce n'est pas une probabilité de malignité. Il est néanmoins utilisé comme score continu pour calculer l'AUC.

3.3 Choix d'implémentation

Élément	Convention retenue
Écarts-types	Estimation avec `ddof=1`
Dénominateur nul	Poids fixé à zéro
Égalité de poids absolus	Tri stable, suivant l'ordre des colonnes
Nombre de variables	Dix dans chaque modèle
Seuil	Malin si le vote est positif ou nul
Estimations	Entraînement uniquement, pour chaque pli
Échelle des variables	Valeurs brutes, conformément à la formule du sujet

Table 3: Conventions permettant de reproduire l'implémentation.

3.4 Effet des unités

Le poids w_j est invariant à une multiplication positive d'une variable par une constante. En revanche, le terme $(x_j - b_j)$ est multiplié par cette constante : la contribution au vote dépend donc de l'échelle. Une mesure d'aire peut peser davantage dans la somme qu'une proportion, même avec des poids comparables.

Cette propriété mérite une attention particulière lorsque l'on transpose une méthode à des variables de nature et d'unités différentes. La présente expérience conserve les valeurs brutes pour respecter le protocole imposé. Une analyse complémentaire des contributions ou une variante standardisée permettrait d'étudier cet effet, mais ne doit pas être confondue avec les résultats de la méthode évaluée ici.

4 Protocole d'évaluation

4.1 Partitions au niveau du patient

La validation utilise `RepeatedStratifiedKFold` avec cinq plis, trois répétitions et la graine **23**. Quinze modèles sont ainsi évalués pour chaque méthode. Chaque patient est validé une fois par répétition. Les ensembles d'entraînement et de validation sont disjoints dans un pli ; l'entraînement contient 455 ou 456 patients et la validation 113 ou 114.

La stratification conserve approximativement la répartition des diagnostics. Moyennes, écarts-types, poids, milieux et variables sélectionnées sont calculés uniquement sur l'entraînement. Le patient validé n'intervient dans aucune de ces estimations.

4.2 Indicateurs et exemple prédéfini

La *balanced accuracy* est la moyenne de la sensibilité et de la spécificité :

$$\mathrm{BA} = \frac{1}{2}\left(\frac{VP}{VP+FN} + \frac{VN}{VN+FP}\right).$$

Elle donne le même poids aux deux classes. L'AUC mesure la capacité du score à ordonner un cas malin au-dessus d'un cas bénin à travers les seuils possibles. Sensibilité et spécificité rendent visibles les deux types d'erreurs au seuil retenu.

Le premier pli de la première répétition a été choisi à l'avance comme exemple. Il contient 71 patients bénins et 43 malins. Il ne représente pas le meilleur pli sélectionné après examen des scores.

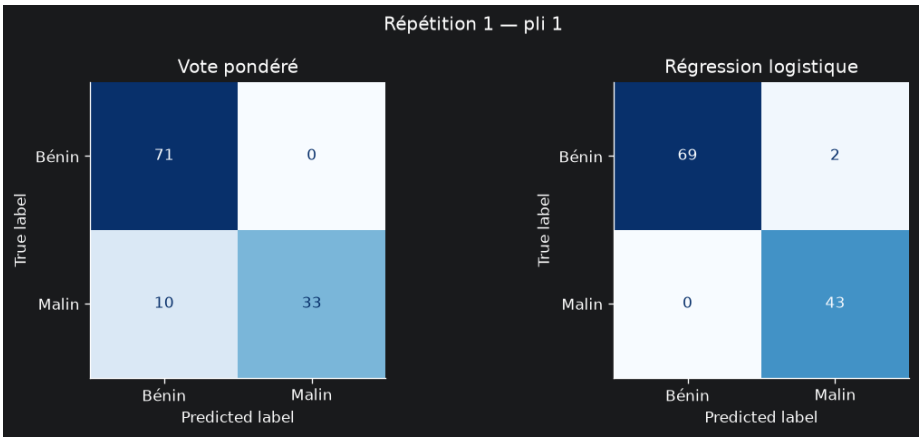


Figure 2: Matrices de confusion du premier pli. Lignes : diagnostic réel ; colonnes : diagnostic prédit.

Méthode	AUC	BA	Sensibilité	Spécificité
Vote pondéré	0,9712	0,8837	0,7674	1,0000
Logistique	1,0000	0,9859	1,0000	0,9718

Table 4: Performances du premier pli ; BA : balanced accuracy.

Le vote pondéré manque 10 des 43 cas malins, sans faux positif sur ce pli. La logistique ne manque aucun cas malin, mais classe deux cas bénins comme malins. Ces résultats illustrent des comportements distincts ; ils doivent être replacés dans l'ensemble des quinze évaluations.

5 Performances et comparaison

5.1 Régression logistique de référence

La régression logistique utilise les trente variables sur exactement les mêmes partitions. Un `StandardScaler` est ajusté sur chaque entraînement, puis appliqué à la validation dans un pipeline. Les paramètres sont ceux du sujet : `solver="liblinear"`, $C = 1,0$, `max_iter=1000`, sans pondération des classes ni recherche d'hyperparamètres. Le seuil de décision est fixé à 0,5.

5.2 Résultats moyens

Indicateur	Vote pondéré	Logistique
AUC	$0,9622 \pm 0,0125$	$0,9947 \pm 0,0059$
Balanced accuracy	$0,8561 \pm 0,0370$	$0,9739 \pm 0,0085$
Sensibilité	$0,7263 \pm 0,0792$	$0,9590 \pm 0,0209$
Spécificité	$0,9860 \pm 0,0130$	$0,9888 \pm 0,0152$

Table 5: Moyenne ± écart-type des scores des quinze plis.

L'AUC élevée du vote pondéré montre que son score contient une information permettant de distinguer les deux diagnostics. Cependant, sa balanced accuracy est plus faible : au seuil de vote nul, le modèle reconnaît très bien les cas bénins, mais manque une part importante des cas malins. La sensibilité moyenne de 72,63 % correspond à un taux moyen de faux négatifs de 27,37 % parmi les cas malins des plis. Une bonne AUC ne garantit donc pas un seuil de décision adapté à la question clinique.

La logistique atteint une balanced accuracy de 97,39 % et une sensibilité de 95,90 %, avec une spécificité proche de celle du vote. Les écarts moyens sont de **11,78 points** pour la balanced accuracy et de **23,27 points** pour la sensibilité, en faveur de la logistique. Sa dispersion entre plis est aussi plus faible pour l'AUC et la balanced accuracy.

5.3 Portée de la comparaison

Les partitions communes limitent l'influence d'une différence d'échantillonnage entre méthodes. Elles ne rendent pas pour autant les deux modèles identiques : la logistique utilise trente variables standardisées et apprend conjointement leurs coefficients, tandis que le vote en retient dix selon un critère individuel et additionne des contributions sur les valeurs brutes. L'avantage observé concerne ces deux pipelines précis ; il ne démontre pas la supériorité de la logistique pour tout jeu de données ou toute variante de vote pondéré.

Les scores présentés sont des moyennes par pli, et non une unique performance obtenue sur une cohorte externe. Les entraînements se chevauchent et les mêmes patients réapparaissent dans plusieurs répétitions. Les quinze scores sont donc dépendants. Leur écart-type décrit la dispersion observée et ne constitue ni un intervalle de confiance ni un test de significativité. Aucun ajustement du seuil n'a été réalisé après consultation des validations.

6 Stabilité de la sélection

6.1 Fréquences et recouvrement

Les dix variables sélectionnées sont enregistrées dans chaque pli d'entraînement. Leur fréquence est le nombre de sélections divisé par quinze. La similarité entre deux sélections est mesurée par :

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}.$$

La moyenne porte sur les $\binom{15}{2} = 105$ paires et vaut **0,9550**. Neuf variables sont présentes dans tous les modèles : `mean_radius`, `mean_perimeter`, `mean_area`, `mean_concavity`, `mean_concave_points`, `worst_radius`, `worst_perimeter`, `worst_area` et `worst_concave_points`.

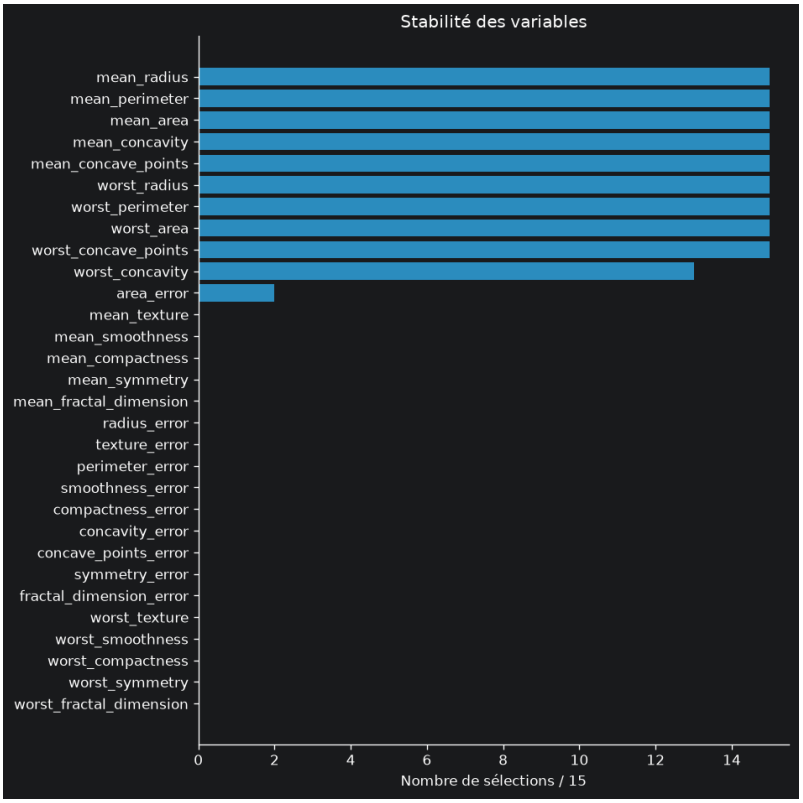


Figure 3: Nombre de sélections de chacune des trente variables, sur quinze entraînements.

La dernière place revient à `worst_concavity` dans 13 plis (86,7 %) et à `area_error` dans deux plis (13,3 %). Les dix-neuf autres variables ne sont jamais retenues. L'identité des variables est donc très stable dans ce rééchantillonnage interne.

6.2 Stabilité prédictive et identité des variables

Cette stabilité ne signifie pas que le modèle est assez précis. La balanced accuracy du vote varie entre plis, avec un écart-type de 0,0370, et sa sensibilité reste limitée. Un ensemble presque constant de variables peut produire une décision systématiquement défavorable à certains cas malins. De plus, les variables stables décrivent souvent des propriétés liées : leur fréquence ne prouve ni une contribution indépendante ni une relation causale avec le diagnostic. Une stabilité observée sur cette cohorte ne garantit pas la même sélection dans un autre centre.

7 Interprétation clinique et limites

7.1 Ce que l'expérience permet de conclure

Dans ces données, le vote pondéré produit un score discriminant et une sélection de variables stable, mais sa sensibilité au seuil imposé est insuffisante pour recommander un usage diagnostique autonome. Manquer environ 27 % des cas malins en moyenne entre plis constitue une limite majeure, malgré une spécificité de 98,6 %. La logistique donne de meilleurs résultats internes, sans être pour autant validée pour une utilisation clinique.

L'expérience teste une relation entre des **résumés morphologiques déjà extraits** et le diagnostic fourni. Elle ne teste pas l'ensemble du dispositif de diagnostic : le modèle ne reçoit ni les cellules, ni une lame, ni une image brute. Une bonne performance sur le tableau ne démontre pas que les mêmes mesures seraient obtenues de façon fiable dans une nouvelle chaîne d'acquisition.

7.2 Validité des données et généralisation

Le tableau ne fournit pas de dates de collecte, d'identifiants de centre ou de lot, de variables démographiques, d'antécédents cliniques, de masques de segmentation ou de comptes rendus anatomopathologiques. Il n'expose pas non plus la vérification du diagnostic pour chaque ligne. Ces absences limitent l'audit des labels, l'étude des effets de site et l'analyse des erreurs selon le profil du patient. Elles ne démontrent pas que les diagnostics sont incorrects, mais empêchent de le vérifier indépendamment dans cette étude.

La validation est interne à la série de développement. Les patients d'une validation partagent ainsi l'origine et la préparation générale des données d'entraînement. Les 54 nouveaux patients du travail source ne sont pas disponibles ici. Les bonnes performances de la logistique ne peuvent donc pas être présentées comme une reproduction de ce test externe.

Enfin, la population avait déjà une masse mammaire prélevée. La proportion de cas malins et le contexte de mesure sont différents de ceux d'un dépistage de personnes asymptomatiques. Aucune conclusion n'est possible sur le risque futur de cancer, la survie, la réponse au traitement ou la détection dans la population générale.

7.3 Analyses complémentaires nécessaires

Une validation externe devrait appliquer un modèle fixé à l'avance à des patients d'autres centres, avec des conditions d'acquisition documentées. Une évaluation prospective permettrait ensuite d'examiner son comportement dans le parcours clinique réel. Les erreurs, notamment les faux négatifs, devraient être étudiées et mises en relation avec les conséquences d'une décision.

Il faudrait également tester la reproductibilité des mesures, la sensibilité aux variations de segmentation et l'influence des unités sur les contributions au vote. Une éventuelle adaptation du seuil devrait être définie sur les seules données d'entraînement, avec une procédure de validation appropriée, puis testée sur des patients indépendants. Elle ne peut pas être justifiée en choisissant le meilleur seuil sur les plis déjà évalués. Pour la logistique, l'évaluation de la calibration serait utile si ses probabilités servaient à une décision clinique.

Recommandation. Le vote pondéré constitue ici une méthode simple et interprétable pour une étude exploratoire. Les résultats ne justifient pas son utilisation autonome pour exclure une malignité. La logistique est une référence plus performante dans ce protocole, mais les deux méthodes nécessitent une validation clinique supplémentaire.

8 Reproductibilité et conclusion

8.1 Reconstruction de la méthode publiée

L'article de Golub fournit le principe du vote et détaille en notes la sélection et les paramètres. La sélection est refaite à chaque validation. Il décrit aussi des valeurs d'expression transformées et normalisées, ainsi qu'une force de prédiction permettant de laisser certains échantillons incertains [1]. Ces éléments montrent qu'une équation seule ne définit pas toute l'expérience.

Notre protocole retient dix variables selon $|w_j|$, utilise les valeurs WDBC brutes et force une classe à chaque patient au seuil zéro. Ces choix viennent du sujet. La mise en œuvre reproduit donc le vote demandé, sans reconstituer exactement le pipeline de leucémie de la publication. L'application ne permet pas de confirmer les résultats originaux, puisqu'elle change à la fois la maladie, les mesures et l'évaluation.

8.2 Conditions d'une reproduction numérique

La formule permet de reconstruire le cœur du calcul, mais une reproduction numérique exige de préciser les écarts-types, les égalités de classement, les dénominateurs nuls, les transformations, les seuils et la composition des ensembles d'entraînement. Dans notre implémentation, ces conventions sont explicites. Le CSV fourni est conservé, la graine est fixée à 23 et les versions de dépendances sont verrouillées avec `uv.lock`. Le README donne une commande exécutant l'analyse ; les tableaux et figures restent dans le notebook.

Pour faciliter la reproduction d'une méthode publiée, il est utile de distribuer ensemble les données et leur provenance, les scripts de préparation et d'évaluation, les paramètres, les partitions et un environnement logiciel versionné. Des sorties de référence et des tests sur un petit exemple aideraient à vérifier les calculs. Le rôle des compléments doit aussi être clairement indiqué. Il serait excessif d'affirmer que tous ces éléments étaient absents de l'article original sur la seule base de cette application.

8.3 Réponse à la question

Le vote pondéré peut distinguer les deux classes dans WDBC, avec une AUC moyenne de 0,9622 et une sélection stable. En revanche, sa sensibilité de 0,7263 et sa balanced accuracy de 0,8561 au seuil imposé empêchent de conclure à une classification suffisamment fiable des cas malins. La logistique est meilleure dans cette comparaison interne. La robustesse observée concerne le rééchantillonnage des données disponibles ; elle ne vaut pas validation externe ou clinique.

Références

[1] Golub, T. R., et al. (1999). Molecular Classification of Cancer: Class Discovery and Class Prediction by Gene Expression Monitoring. *Science*, 286, 531–537. doi:10.1126/science.286.5439.531.

[2] Wolberg, W., Mangasarian, O., Street, N., et Street, W. *Breast Cancer Wisconsin (Diagnostic)*. UCI Machine Learning Repository. doi:10.24432/C5DW2B.

[3] Street, W. N., Wolberg, W. H., et Mangasarian, O. L. (1993). Nuclear feature extraction for breast tumor diagnosis. *IS&T/SPIE*, 1905, 861–870. doi:10.1117/12.148698.

[4] Wolberg, W. H., Street, W. N., et Mangasarian, O. L. (1994). Machine learning techniques to diagnose breast cancer from image-processed nuclear features of fine needle aspirates. *Cancer Letters*, 77, 163–171. doi:10.1016/0304-3835(94)90099-X.

[5] Scikit-learn, documentation des API de validation croisée, métriques et régression logistique. `https://scikit-learn.org/stable/`. Données fournies : `MANIFEST.json` et `DATA_DICTIONARY.md`.

Assistance : code et rédaction préparés avec l'aide de ChatGPT, à relire et valider avant remise.